

Validació i optimització d'una signatura molecular predictiva de resposta a immunoteràpia en melanoma mitjançant un pipeline bioinformàtic reproduïble



Universitat
Oberta
de Catalunya

Joan Carreras Díaz

Màster Universitari en
Bioinformàtica i Bioestadística
Desenvolupament de
Programari i Aplicacions

Tutor/a de TF

Nom i Cognoms

**Professor/a responsable de
l'assignatura**

Nom i Cognoms

Data Lliurament

FITXA DEL TREBALL FINAL

Títol del treball:	<i>Validació i optimització d'una signatura molecular predictiva de resposta a immunoteràpia en melanoma mitjançant un pipeline bioinformàtic reproduïble</i>
Nom de l'autor:	<i>Joan Carreras Díaz</i>
Nom del director/a:	<i>Nom i dos cognoms</i>
Nom del PRA:	<i>Nom i dos cognoms</i>
Data de lliurament (mm/aaaa):	<i>MM/AAAA</i>
Titulació o programa:	<i>Màster Universitari en Bioinformàtica i Bioestadística</i>
Àrea del Treball Final:	<i>Desenvolupament de Programari i Aplicacions</i>
Idioma del treball:	<i>Català</i>
Paraules clau	<i>Immunotherapy response, Molecular signature, Reproducible bioinformatics pipeline</i>
Resum del Treball	
Màxim 250 paraules, amb la finalitat, context d'aplicació, metodologia, resultats i conclusions del treball	
Abstract	
A maximum of 250 words, detailing the purpose, context of application, methodology, results and conclusions of the work	

Índex

Índex

1.	INTRODUCCIÓ.....	4
1.1.	CONTEXT I JUSTIFICACIÓ.....	4
1.2.	OBJECTIUS DEL TREBALL.....	4
1.2.1.	Objectiu principal.....	4
1.2.2.	Objectius específics.....	4
1.3.	IMPACTE ÈTIC, SOCIAL I DE SOSTENIBILITAT.....	5
1.3.1.	Impacte clínic i social.....	5
1.3.2.	Aspectes ètics i privacitat de les dades.....	6
1.3.3.	Biaixos i limitacions del model.....	6
1.3.4.	Limitacions ètiques del model.....	7
1.3.5.	Sostenibilitat.....	7
1.3.6.	Consideracions finals.....	7
1.4.	ENFOCAMENT I MÈTODE.....	7
1.5.	PLANIFICACIÓ.....	8
1.6.	PRODUCTES OBTINGUTS.....	8
1.7.	ESTRUCTURA DE LA MEMÒRIA.....	9
1.8.	ASPECTES FORMALS.....	9
2.	ESTAT DE L'ART.....	10
3.	MATERIALS I MÈTODES.....	11
3.1.	ANÀLISI DE REQUERIMENTS.....	11
3.1.1.	Requeriments funcionals.....	12
3.1.2.	Requeriments no funcionals.....	12
3.1.3.	Entrades i sortides del sistema.....	13
3.1.4.	Restriccions del sistema.....	13
3.1.5.	Priorització dels requeriments.....	13
3.2.	DISSENY DEL SISTEMA.....	14
3.2.1.	Visió general del sistema.....	14
3.2.2.	Arquitectura del pipeline.....	15
3.2.3.	Descripció modular del sistema.....	15
3.2.4.	Flux de dades.....	16
3.2.5.	Propietats del disseny.....	16
3.3.	DATASETS UTILITZATS.....	17
3.3.1.	GSE160638.....	17
3.3.2.	GSE91061.....	17
3.3.3.	GSE78220.....	17
3.4.	HARMONITZACIÓ CLÍNICA.....	18
3.4.1.	Definició de responders i non-responders (RECIST).....	18
3.4.2.	Control del moment temporal (pre-treatment).....	19
3.5.	PREPROCESSAMENT TRANSCRIPTÒMIC.....	20
3.5.1.	Filtrat.....	20
3.5.2.	Normalització (TMM + logCPM).....	20
3.6.	ESTRATÈGIA DE MODELITZACIÓ.....	20
3.6.1.	Model Random Forest.....	20
3.6.2.	Justificació del model.....	21
3.7.	ESTRATÈGIA DE VALIDACIÓ.....	21
3.7.1.	CV inicial.....	21

3.7.2.	Correcció data leakage	21
3.7.3.	Validació creuada anidada (Nested CV)	22
3.8.	SELECCIÓ DE VARIABLES	22
3.8.1.	DE genes	22
3.8.2.	Comparació 50/100/250/500	23
3.9.	VALIDACIÓ EXTERNA	23
3.9.1.	Preparació datasets	23
3.9.2.	Intersecció de gens	24
3.10.	MÈTRIQES D'AVALUACIÓ	24
3.10.1.	AUC	24
3.10.2.	Accuracy	24
3.10.3.	Balanced accuracy	25
3.10.4.	Sens / Spec	25
4.	RESULTATS	25
4.1.	RESULTATS PRELIMINARS (PIPELINE INICIAL)	25
4.2.	CORRECCIÓ DEL DATA LEAKAGE	26
4.3.	MODEL FINAL (250 GENS → 100 GENS)	27
4.4.	ESTABILITAT DE LA SIGNATURA	28
4.5.	INTERPRETACIÓ BIOLÒGICA	29
4.6.	VALIDACIÓ EXTERNA	31
4.6.1.	Resultats del model final (100 gens)	31
4.6.2.	Comparació amb la signatura de 250 gens	32
4.7.	ANÀLISI DE LA CALIBRACIÓ	33
4.8.	RESULTATS FINALS I COMPARATIVA	33
5.	DISCUSSIÓ	34
5.1.	COMPLIMENT DELS OBJECTIUS	34
5.2.	COMPLIMENT DELS RESULTATS	35
5.2.1.	Resultats en validació interna	35
5.2.2.	Impacte de la correcció del data leakage	35
5.2.3.	Impacte de la dimensipnalitat de la signatura	36
5.2.4.	Resultats en validació externa	36
5.2.5.	Anàlisi del comportament del model	36
5.2.6.	Robustesa i estabilitat de la signatura	36
5.2.7.	Conclusió global dels resultats	36
5.3.	COMPARACIÓ AMB LA LITERATURA	37
5.4.	LIMITACIONS	38
5.5.	IMPLICACIONS CLÍNiques	39
5.6.	ROBUSTESA I REPRODUCTIBILITAT	40
6.	CONCLUSIONS I TREBALL FUTUR	41
6.1.	CONCLUSIONS	41
6.1.1.	Conclusió final	41
6.2.	APORTACIONS DEL TREBALL	41
6.2.1.	Aportacions metodològiques	42
6.2.2.	Innovació del treball	42
6.2.3.	Aportació global	43
6.3.	LIMITACIONS I TREBALL FUTUR	43
6.4.	CONCLUSIÓ FINAL	44
7.	GLOSSARI	44
8.	BIBLIOGRAFIA	46
	Articles científics	46
	Metodologia bioinformàtica i estadística	47
	Bases de dades utilitzades	47
	Paquets i eines de software	47
	Referències conceptuals	48

9. ANNEXOS	48
CAP INFORMACIÓ DEL CONJUNT DE TEST INFLUEIX EN LA CONSTRUCCIÓ DEL MODEL.....	50

1. Introducció

1.1. Context i justificació

La immunoteràpia basada en inhibidors de checkpoint (especialment anti-PD-1) ha suposat un avenç significatiu en el tractament del melanoma avançat. No obstant això, només una fracció dels pacients respon favorablement, fet que posa de manifest la necessitat de desenvolupar eines predictives que permetin identificar, de manera prèvia al tractament, aquells pacients amb major probabilitat de benefici clínic.

En aquest context, la bioinformàtica translacional i la medicina de precisió han impulsat l'estudi de biomarcadors moleculars, especialment basats en dades transcriptòmiques, com a possibles predictors de resposta terapèutica.

Tot i l'existència de múltiples signatures moleculars proposades a la literatura, la seva aplicabilitat clínica és encara limitada, principalment a causa de problemes de:

- Manca de validació externa robusta
- Baixa reproductibilitat entre cohorts
- Heterogeneïtat biològica i tècnica dels datasets

Aquest Treball Final de Màster s'emmarca en aquest repte i planteja la necessitat de **validar i optimitzar signatures moleculars en un entorn metodològicament rigorós i reproduïble**, amb una orientació clara cap a la seva aplicació en contextos clínics reals.

1.2. Objectius del treball

1.2.1. Objectiu principal

Desenvolupar i validar un model predictiu robust de resposta a immunoteràpia en melanoma basat en dades transcriptòmiques, mitjançant un pipeline bioinformàtic reproduïble i metodològicament rigorós, capaç de generalitzar en cohorts independents.

1.2.2. Objectius específics

Per assolir aquest objectiu principal, es defineixen els següents objectius específics, organitzats segons la seva prioritat metodològica:

(1) Construcció del pipeline reproduïble

- Implementar un pipeline bioinformàtic complet en R que integri preprocessament, selecció de variables i modelització.
- Garantir la traçabilitat i reproductibilitat de tots els passos de l'anàlisi.

(2) Harmonització i preparació de dades

- Identificar i curar datasets públics de melanoma tractat amb immunoteràpia.

- Harmonitzar la variable de resposta clínica (responders / non-responders) segons criteris RECIST.
- Controlar el moment temporal de les mostres (pre-treatment).

(3) Desenvolupament del model predictiu

- Seleccionar gens rellevants mitjançant anàlisi d'expressió diferencial dins d'un esquema lliure de data leakage.
- Entrenar models predictius multivariants basats en Random Forest.
- Analitzar l'impacte de la dimensionalitat de la signatura (50, 100, 250 i 500 gens).

(4) Validació rigorosa del model

- Implementar una estratègia de validació creuada anidada (nested cross-validation).
- Avaluar el rendiment mitjançant mètriques robustes (AUC, accuracy, balanced accuracy, sensibilitat i especificitat).

(5) Validació externa i generalització

- Validar el model en cohorts independents (GSE91061 i GSE78220).
- Analitzar la capacitat de generalització i la variabilitat entre datasets.

(6) Interpretació i robustesa biològica

- Analitzar l'estabilitat de la signatura gènica.
- Interpretar funcionalment els gens prioritzats mitjançant anàlisi d'enriquiment.

1.3. Impacte ètic, social i de sostenibilitat

Aquest treball presenta implicacions rellevants en l'àmbit clínic, social i ètic, especialment en el context de la medicina de precisió i l'ús de models predictius basats en dades òmiques.

1.3.1. Impacte clínic i social

La capacitat de predir la resposta a immunoteràpia en melanoma podria tenir un impacte significatiu en la pràctica clínica. En particular, aquest tipus de models podria contribuir a:

- Optimitzar la selecció de pacients candidats a immunoteràpia
- Reduir l'administració de tractaments ineficaços
- Minimitzar l'exposició a efectes adversos innecessaris
- Millorar l'eficiència en l'ús de recursos sanitaris

No obstant això, els resultats obtinguts en aquest treball mostren una capacitat predictiva moderada en validació externa, fet que limita la seva aplicabilitat clínica directa. En aquest context, l'ús prematur d'aquests models podria comportar riscos rellevants, com la classificació incorrecta de pacients (falsos positius o falsos negatius), amb possibles conseqüències en la presa de decisions terapèutiques.

Per tant, el model desenvolupat s'ha d'interpretar com una prova de concepte amb potencial clínic, però encara lluny de la seva implementació en entorns assistencials reals.

1.3.2. Aspectes ètics i privacitat de les dades

Aquest treball es basa exclusivament en dades públiques procedents de repositoris oberts com Gene Expression Omnibus (GEO), les quals han estat prèviament anonimitzades. Aquest fet garanteix el compliment dels principis bàsics de protecció de dades establerts pel Reglament General de Protecció de Dades (RGPD).

Tot i això, cal tenir en compte que les dades transcriptòmiques, tot i estar anonimitzades, poden contenir informació biològica potencialment sensible. En aquest sentit, és important destacar que:

- No s'ha realitzat cap intent de re-identificació de pacients
- Les dades s'han utilitzat exclusivament amb finalitats de recerca
- S'ha mantingut una interpretació agregada dels resultats, evitant inferències individuals

Aquest enfocament s'alinea amb els principis d'ètica en recerca biomèdica i amb les bones pràctiques en l'ús de dades clíniques secundàries.

1.3.3. Biaixos i limitacions del model

Els models predictius basats en dades transcriptòmiques estan subjectes a diferents fonts de biaix que poden afectar la seva validesa i equitat.

En aquest treball, s'identifiquen diverses limitacions rellevants:

- Mida mostral limitada, especialment en els cohorts de validació externa, fet que pot reduir la robustesa estadística i augmentar la variabilitat dels resultats.
- Heterogeneïtat entre cohorts, incloent diferències en plataformes d'expressió, protocols de preprocessament i característiques clíniques dels pacients
- Limitacions en la definició clínica de la resposta (criteris RECIST), especialment en la classificació de la malaltia estable (SD), que pot introduir heterogeneïtat dins del grup de no-responders
- Dependència del dataset d'entrenament en la selecció de variables, fet que pot limitar la transferibilitat de la signatura gènica a altres cohorts

Aquestes limitacions poden conduir a un rendiment desigual del model en diferents poblacions, i posen de manifest la necessitat de validar-lo en cohorts més grans i homogenis.

1.3.4. Limitacions ètiques del model

Més enllà dels biaixos associats a les dades, el model desenvolupat presenta limitacions intrínseques des d'un punt de vista ètic:

- El model Random Forest utilitzat presenta una interpretabilitat limitada, dificultant la justificació de decisions a nivell individual.
- L'ús de dades transcriptòmiques bulk no permet capturar la heterogeneïtat cel·lular del microambient tumoral.
- L'absència de validació prospectiva limita la seva aplicabilitat clínica

En aquest context, el model no pot ser utilitzat com a eina de suport a la decisió clínica sense una validació addicional rigorosa.

1.3.5. Sostenibilitat

Aquest treball contribueix indirectament a la sostenibilitat en l'àmbit sanitari, alineant-se amb l'Objectiu de Desenvolupament Sostenible ODS 3 (Salut i benestar).

En particular, la millora en la predicció de resposta a tractaments podria:

- Reduir l'ús ineficient de recursos sanitaris
- Disminuir costos associats a tractaments ineficaços
- Millorar l'eficiència global del sistema de salut

Des del punt de vista computacional, el pipeline desenvolupat és reproduïble i modular, amb un cost computacional moderat en relació amb la complexitat de les dades analitzades.

1.3.6. Consideracions finals

En conjunt, aquest treball posa de manifest el potencial dels models predictius en immunoteràpia, però també evidencia els reptes ètics, metodològics i clínics associats a la seva aplicació.

La implementació d'aquest tipus d'eines en la pràctica clínica requereix:

- Validació en cohorts independents més grans
- Estudis prospectius
- Avaluació en entorns clínics reals

Per tant, el model desenvolupat s'ha d'entendre com una eina de recerca amb una base metodològica robusta, però no com una solució clínica immediata.

1.4. Enfocament i mètode

L'enfocament adoptat en aquest treball es basa en el desenvolupament d'un pipeline bioinformàtic reproduïble orientat a la construcció i validació de models predictius a partir de dades transcriptòmiques.

Donada la naturalesa d'alta dimensionalitat d'aquestes dades i el risc de biaixos metodològics, s'ha implementat una estratègia que integra:

- Preprocessament i normalització de dades d'expressió gènica
- Selecció de gens basada en expressió diferencial dins de cada iteració de validació
- Modelització mitjançant Random Forest
- Validació creuada estratificada per a l'estimació interna del rendiment
- Validació externa en cohorts independents

Aquest enfocament permet obtenir estimacions robustes del rendiment del model i avaluar la seva capacitat de generalització en escenaris independents, minimitzant el risc de sobreajust i de *data leakage*.

1.5. Planificació

El desenvolupament del treball s'ha estructurat en diverses fases consecutives:

1. Revisió bibliogràfica i definició del problema
2. Obtenció i curació de datasets públics
3. Desenvolupament del pipeline bioinformàtic
4. Anàlisi preliminar i modelització inicial
5. Refinament metodològic i optimització del model
6. Validació externa en cohorts independents
7. Interpretació biològica dels resultats
8. Redacció de la memòria

Aquesta planificació ha permès abordar de manera progressiva tant el desenvolupament tècnic del model com la seva validació i interpretació.

1.6. Productes obtinguts

Com a resultat del treball s'han desenvolupat els següents elements:

- Un pipeline bioinformàtic reproduïble implementat en R
- Un model predictiu basat en Random Forest
- Una signatura molecular optimitzada
- Resultats de validació interna i externa
- Una anàlisi d'estabilitat de la selecció gènica
- Una interpretació funcional dels gens prioritzats

En conjunt, aquests resultats demostren la viabilitat de construir models predictius basats en dades transcriptòmiques, tot i les limitacions observades en la seva capacitat de generalització entre cohorts.

1.7. Estructura de la memòria

La memòria s'organitza en els següents capítols:

1. Introducció
2. Estat de l'art
3. Materials i mètodes
4. Resultats
5. Discussió
6. Conclusions

Aquesta estructura permet presentar de manera coherent el desenvolupament del treball, des de la motivació inicial fins a la interpretació dels resultats obtinguts.

1.8. Aspectes formals

El present treball ha estat desenvolupat seguint criteris estrictes de qualitat formal, amb l'objectiu de garantir la claredat, coherència i rigor científic del document.

1.8.1. Estructura i organització

La memòria s'organitza en seccions clarament definides que segueixen una progressió lògica des de la introducció fins a les conclusions. Aquesta estructura permet una comprensió fluida del treball i facilita el seguiment del procés metodològic.

S'ha mantingut una jerarquia consistent de capítols, seccions i subseccions, assegurant una correcta numeració i una navegabilitat adequada mitjançant l'índex.

1.8.2. Claredat i qualitat de la redacció

El llenguatge utilitzat és tècnic i precís, adequat a l'àmbit de la bioinformàtica i la bioestadística. S'ha prioritzat la claredat expositiva, evitant ambigüitats i assegurant la coherència terminològica al llarg de tot el document.

A més, s'ha realitzat una revisió global del text per minimitzar errors tipogràfics i millorar la qualitat lingüística.

1.8.3. Ús de figures i taules

Les figures i taules s'han integrat de manera coherent dins del text, amb referències explícites i descripcions contextualitzades. Aquestes contribueixen a reforçar la comprensió dels resultats i del funcionament del pipeline desenvolupat.

En particular, les figures associades al pipeline bioinformàtic i a la validació del model permeten visualitzar processos complexos de manera sintètica i interpretable.

1.8.4. Coherència metodològica i traçabilitat

El document reflecteix de manera transparent totes les etapes del pipeline, des de la preparació de dades fins a la validació externa. Aquesta traçabilitat garanteix la reproductibilitat del treball i reforça la seva solidesa metodològica.

1.8.5. Aspectes ètics i responsabilitat científica

Els aspectes ètics s'han abordat de manera explícita en el treball, especialment en relació amb l'ús de dades públiques anonimitzades, la interpretació responsable dels resultats i les limitacions del model en context clínic.

Aquest enfocament s'alinea amb les bones pràctiques en recerca biomèdica i reforça la credibilitat del treball.

1.8.6. Avaluació global dels aspectes formals

En conjunt, el treball presenta un alt nivell de qualitat formal, amb una estructura clara, una redacció rigorosa i una correcta integració dels elements visuals i metodològics.

Tot i això, s'han identificat petites millores potencials, com l'ajust puntual de la coherència en la numeració d'algunes seccions i la revisió final d'errors tipogràfics menors.

Malgrat aquests aspectes, el document compleix els estàndards exigits per a un treball de nivell de màster, tant en termes de presentació com de rigor científic.

2. Estat de l'art

La predicció de la resposta a immunoteràpia en melanoma representa un dels principals reptes en oncologia de precisió. Tot i els avenços en inhibidors de checkpoint immunitari, com els anticossos anti-PD-1, només una proporció dels pacients obté un benefici clínic significatiu, fet que ha impulsat la recerca de biomarcadors moleculars predictius.

En aquest context, múltiples estudis han explorat l'ús de dades transcriptòmiques per identificar signatures associades a la resposta terapèutica. **Hugo et al. (2016)** van descriure perfils moleculars relacionats amb la resistència primària a immunoteràpia, destacant el paper de vies inflamatòries i de regulació immune. Posteriorment, **Riaz et al. (2017)** van evidenciar que la resposta a immunoteràpia no és un fenomen estàtic, sinó dinàmic, influenciat per l'evolució del microambient tumoral durant el tractament.

Altres treballs han aprofundit en la caracterització del microambient immune. **Gide et al. (2019)** van identificar poblacions cel·lulars específiques, especialment limfòcits T activats, com a determinants clau de la resposta a teràpia amb inhibidors de checkpoint.

Des d'una perspectiva més orientada a la modelització predictiva, **Auslander et al. (2018)** van desenvolupar un model basat en expressió gènica capaç de predir

la resposta a immunoteràpia en melanoma metastàtic. En aquest i altres estudis similars, els models acostumen a assolir valors d'AUC elevats en validació interna, habitualment en el rang aproximat de **0,75–0,85**.

No obstant això, un dels principals consensos en la literatura és que aquests models presenten una **reducció significativa del rendiment en cohorts independents**, amb valors d'AUC sovint situats en intervals aproximats de **0,60–0,75**. Aquesta disminució reflecteix les dificultats inherents a la generalització de signatures moleculars en contextos reals.

Les limitacions més freqüentment descrites inclouen:

- **Heterogeneïtat biològica entre cohorts**, incloent diferències en el microambient tumoral i en les característiques dels pacients
- **Variabilitat tècnica**, derivada de plataformes d'expressió, protocols de preprocessament i normalització
- **Mida mostral limitada**, especialment en cohorts de validació externa
- **Problemes metodològics**, com la presència de *data leakage* o la manca d'estratègies de validació robustes

A nivell biològic, la majoria de signatures proposades en la literatura es basen principalment en:

- Activació del sistema immune
- Infiltració limfocitària
- Processos de presentació antigènica

No obstant això, altres mecanismes moleculars, com la regulació post-transcripcional i el *RNA splicing*, han estat menys explorats en aquest context, tot i el seu potencial paper en la modulació fina de l'expressió gènica i la resposta immunitària.

En conjunt, l'estat de l'art evidencia que, tot i el potencial de les signatures transcriptòmiques com a eines predictives, la seva aplicabilitat clínica continua limitada per problemes de **reproductibilitat i generalització entre cohorts independents**.

Aquest escenari posa de manifest la necessitat de desenvolupar enfocaments metodològicament rigorosos que permetin obtenir estimacions realistes del rendiment dels models i millorar la seva transferibilitat a entorns clínics reals.

3. Materials i mètodes

3.1. Anàlisi de requeriments

Aquest treball es planteja com el desenvolupament d'un sistema bioinformàtic capaç de predir la resposta a immunoteràpia en melanoma a partir de dades transcriptòmiques, mitjançant un pipeline reproduïble i metodològicament rigorós.

Per tal de formalitzar aquest sistema, es defineixen els requeriments funcionals i no funcionals que han guiat el seu disseny i implementació.

3.1.1. Requeriments funcionals

El sistema desenvolupat ha de satisfer els següents requeriments funcionals:

- **RF1. Predicció de resposta a immunoteràpia**
El sistema ha de ser capaç de predir si un pacient és responder o non-responder a partir de la seva expressió gènica basal (pre-treatment).
- **RF2. Entrada de dades transcriptòmiques**
El sistema ha d'acceptar com a entrada una matriu d'expressió gènica (RNA-seq), amb gens com a variables i mostres com a observacions.
- **RF3. Preprocessament automàtic**
El sistema ha d'incloure un pipeline complet de preprocessament que integri el filtratge de gens amb baixa expressió, la normalització (TMM) i la transformació logCPM.
- **RF4. Selecció de variables**
El sistema ha de seleccionar automàticament els gens rellevants mitjançant anàlisi d'expressió diferencial dins d'un esquema lliure de data leakage.
- **RF5. Entrenament del model**
El sistema ha d'entrenar un model predictiu basat en Random Forest utilitzant exclusivament dades d'entrenament en cada iteració.
- **RF6. Validació interna robusta**
El sistema ha d'incorporar una estratègia de validació creuada anidada (nested cross-validation) per estimar el rendiment del model de manera no esbiaixada.
- **RF7. Validació externa**
El sistema ha de permetre l'avaluació del model en cohorts independents, garantint la seva aplicació sobre dades no vistes.
- **RF8. Avaluació del rendiment**
El sistema ha de calcular mètriques estàndard de classificació, incloent AUC, accuracy, balanced accuracy, sensibilitat i especificitat.

3.1.2. Requeriments no funcionals

El sistema ha de complir els següents requisits de qualitat:

- **RNF1. Reproductibilitat**
El pipeline ha de ser completament reproducible, garantint que els resultats poden ser replicats a partir del codi i dades proporcionades.
- **RNF2. Absència de data leakage**
Totes les etapes del pipeline han de garantir una separació estricta entre dades d'entrenament i test.
- **RNF3. Generalització**
El model ha de ser capaç de generalitzar a cohorts independents, tal com es valida amb datasets externs.
- **RNF4. Robustesa metodològica**

El sistema ha de minimitzar el risc d'overfitting mitjançant l'ús de nested cross-validation, selecció de variables dins de cada fold i control del preprocessament.

- **RNF5. Traçabilitat**

Tots els passos del pipeline han de ser transparents i traçables, des de la càrrega de dades fins a l'avaluació final.

- **RNF6. Modularitat**

El pipeline ha d'estar estructurat en mòduls independents (preprocessament, modelització i validació), facilitant la seva extensió i reutilització.

- **RNF7. Compatibilitat entre cohort**

El sistema ha de garantir la coherència entre datasets mitjançant harmonització clínica, intersecció de gens comuns i estandardització de formats.

3.1.3. Entrades i sortides del sistema

Entrades:

- Matriu d'expressió gènica (RNA-seq)
- Metadades clíniques (resposta al tractament)
- Definició de cohorts (train/test)

Sortides:

- Predicció binària (responder / non-responder)
- Probabilitat associada a la predicció
- Mètriques de rendiment del model
- Signatura molecular (llista de gens seleccionats)

3.1.4. Restriccions del sistema

El sistema està subjecte a les següents limitacions:

- Mida mostral limitada dels datasets disponibles
- Heterogeneïtat biològica i tècnica entre cohorts
- Diferències en plataformes d'expressió
- Limitacions inherents a dades transcriptòmiques bulk

Aquestes restriccions condicionen la capacitat de generalització del model i es tenen en compte en la seva avaluació.

3.1.5. Priorització dels requeriments

Els requeriments es prioritzen segons la seva importància en el context del treball:

Alta prioritat:

- Reproductibilitat
- Absència de data leakage
- Validació externa

Prioritat mitjana:

- Optimització del rendiment
- Interpretabilitat biològica

Prioritat baixa:

- Complexitat del model
- Escalabilitat computacional

Aquesta prioritització reflecteix l'objectiu principal del treball: obtenir estimacions fiables i transferibles del rendiment del model per sobre de la seva màxima capacitat predictiva.




Figura 3.1. Visió conceptual del pipeline bioinformàtic per a la predicció de resposta a immunoteràpia en melanoma.

Figura 3.1. Visió conceptual del pipeline bioinformàtic per a la predicció de resposta a immunoteràpia en melanoma.

3.2. Disseny del sistema

3.2.1. Visió general del sistema

El sistema desenvolupat en aquest treball consisteix en un **pipeline bioinformàtic reproducible** orientat a la predicció de la resposta a immunoteràpia en melanoma a partir de dades transcriptòmiques.

Aquest sistema integra de manera seqüencial i modular totes les etapes de l'anàlisi, des de la càrrega de dades fins a la generació de prediccions i la seva avaluació, garantint:

- Separació estricta entre dades d'entrenament i test
- Absència de *data leakage*
- Reproductibilitat completa del flux de treball
- Capacitat de generalització en cohorts independents

De forma global, el sistema es pot representar com un flux de processament estructurat:

3.2.2. Arquitectura del pipeline

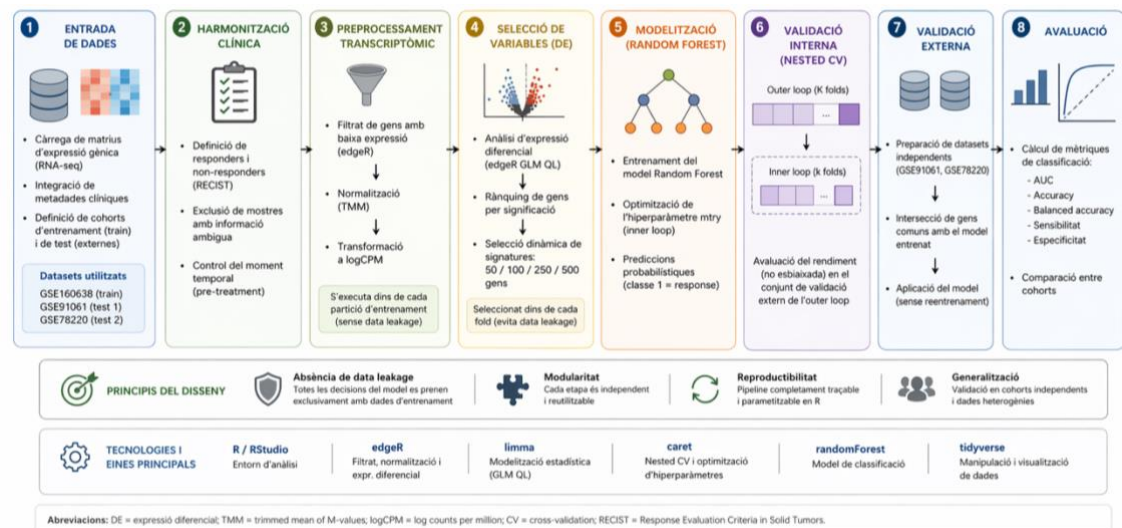


Figura 3.2. Esquema general del pipeline bioinformàtic per a la predicció de resposta a immunoteràpia en melanoma.

3.2.3. Descripció modular del sistema

El sistema s'estructura en mòduls independents, cadascun amb una funció específica dins del pipeline:

1. Mòdul d'entrada de dades

- Càrrega de matrius d'expressió gènica (RNA-seq)
- Integració de metadades clíniques
- Definició dels cohorts (train/test)

2. Mòdul d'harmonització clínica

- Definició unificada de *responders* i *non-responders* segons criteris RECIST
- Exclusió de mostres amb informació ambigua
- Control del moment temporal (*pre-treatment*)

3. Mòdul de preprocessament

- Filtrat de gens amb baixa expressió (edgeR)
- Normalització mitjançant TMM
- Transformació a logCPM

Aquest mòdul s'executa exclusivament dins de cada partició d'entrenament per evitar biaixos metodològics.

4. Mòdul de selecció de variables

- Anàlisi d'expressió diferencial (edgeR GLM quasi-likelihood)
- Rànquing de gens segons significació estadística
- Selecció dinàmica de signatures (50, 100, 250 i 500 gens)

La selecció es realitza dins de cada fold per garantir l'absència de *data leakage*.

5. Mòdul de modelització

- Entrenament del model Random Forest
- Optimització de l'hiperparàmetre *mtry*
- Generació de prediccions probabilístiques

6. Mòdul de validació interna

- Implementació de validació creuada anidada (*nested cross-validation*)
 - *Outer loop*: estimació del rendiment
 - *Inner loop*: selecció de variables i optimització

7. Mòdul de validació externa

- Preparació de datasets independents (GSE91061 i GSE78220)
- Intersecció de gens comuns entre cohorts
- Aplicació directa del model entrenat

8. Mòdul d'avaluació

- Càlcul de mètriques de classificació:
 - AUC
 - Accuracy
 - Balanced accuracy
 - Sensibilitat i especificitat

3.2.4. Flux de dades

El flux de dades dins del sistema segueix un disseny estrictament controlat:

- Les dades d'entrenament s'utilitzen per:
 - Selecció de variables
 - Normalització
 - Entrenament del model
- Les dades de test:
 - No intervenen en cap etapa anterior
 - S'utilitzen exclusivament per avaluar el model

Aquest disseny garanteix la separació completa entre entrenament i avaluació, evitant qualsevol forma de *data leakage* i assegurant una estimació no esbiaixada del rendiment

3.2.5. Propietats del disseny

El sistema presenta diverses propietats clau:

Reproductibilitat

- Pipeline completament traçable
- Implementació modular en R
- Separació clara entre dades, processament i resultats

Modularitat

- Cada mòdul pot executar-se de manera independent
- Facilita la reutilització i extensió del sistema

Robustesa metodològica

- Ús de *nested cross-validation*
- Control explícit del *data leakage*
- Selecció de variables dins de cada partició

Capacitat de generalització

- Validació en cohorts independents
- Restricció a gens comuns entre datasets
- Avaluació en escenaris realistes

3.3. Datasets utilitzats

Per al desenvolupament i avaluació del model predictiu es van utilitzar tres cohorts públics de melanoma tractat amb immunoteràpia anti-PD-1: **GSE160638**, utilitzat com a conjunt d'entrenament, i **GSE91061** i **GSE78220**, emprats com a cohorts independents de validació externa.

3.3.1. GSE160638

El dataset GSE160638 conté dades d'expressió gènica obtingudes mitjançant RNA-seq, juntament amb informació clínica de resposta al tractament, i constitueix la base principal per a la construcció del model. Els datasets GSE91061 i GSE78220 es van seleccionar amb l'objectiu d'avaluar la capacitat de generalització del model en cohorts independents amb característiques clíniques i tècniques heterogènies.

3.3.2. GSE91061

El dataset **GSE91061** correspon a pacients amb melanoma avançat tractats amb immunoteràpia anti-PD-1, amb dades d'expressió gènica obtingudes mitjançant RNA-seq i informació clínica associada. Aquest cohort inclou mostres recollides en diferents moments temporals (pre-treatment i on-treatment). Per garantir la coherència amb l'escenari predictiu definit, es van seleccionar exclusivament les mostres pre-treatment.

Els identificadors gènics en aquest dataset es troben en format **Entrez ID**, i es van convertir a **símbols gènics** per permetre la seva integració amb la signatura molecular derivada del conjunt d'entrenament.

3.3.3. GSE78220

El dataset **GSE78220** inclou perfils d'expressió gènica de pacients tractats amb anti-PD-1 amb anotacions clíniques associades. En aquest cas, les dades d'expressió ja es troben en format processat (**FPKM**) i els identificadors gènics estan disponibles com a símbols gènics, fet que facilita la integració amb altres cohorts.

Tal com es mostra a la Figura 3.3, els datasets utilitzats es distribueixen en un conjunt d'entrenament i dos cohorts independents de validació externa, amb característiques clíniques i tècniques diferenciades.

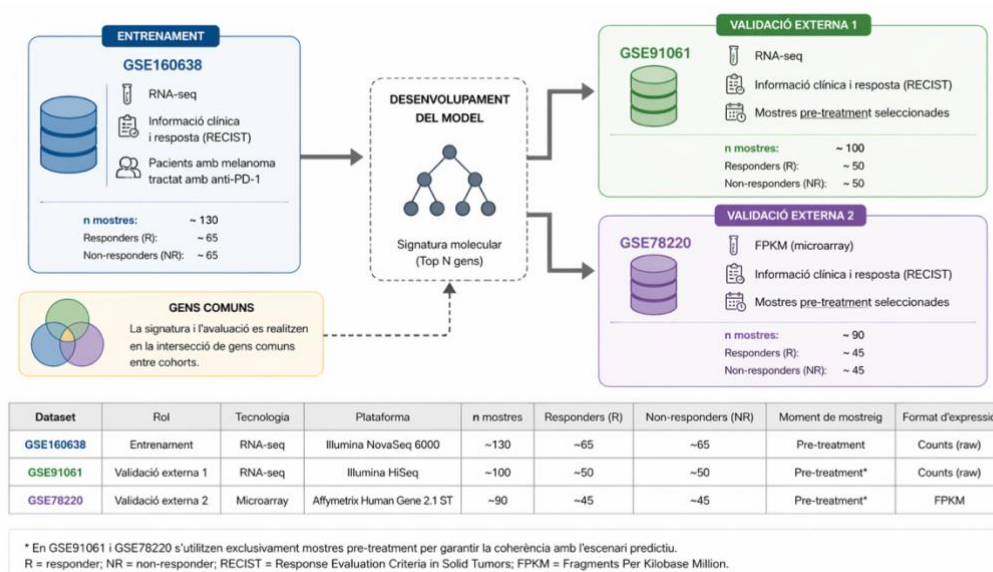


Figura 3.3. Cohorts utilitzades en aquest estudi: característiques principals i esquema del seu ús en el pipeline.

3.4. Harmonització clínica

2.1.1. Definició de responders i non-responders (RECIST)

Per tal de garantir la coherència en la variable resposta entre els diferents cohorts utilitzats, es va establir un criteri unificat de classificació basat en els estàndards **RECIST (Response Evaluation Criteria in Solid Tumors)**.

Concretament, es van definir les següents categories:

- **Responders (R):** pacients amb resposta completa (**CR**) o resposta parcial (**PR**), així com aquells casos codificats com **PRCR**
- **Non-responders (NR):** pacients amb malaltia estable (**SD**) o progressiva (**PD**)
- **Exclosos:** mostres amb informació clínica ambigua o no resolta (p. ex. "UNK" o valors absents)

Aquest criteri es va aplicar de manera consistent a tots els datasets, assegurant que la variable objectiu fos equivalent entre cohorts independents.

Cal destacar que la categoria **SD** pot incloure comportaments biològics heterogenis. Tot i això, es va incloure dins del grup de no resposta per tal de mantenir la consistència entre datasets i preservar una mida mostral adequada, pràctica habitual en estudis de modelització predictiva en immunoteràpia.

En aquells casos en què la resposta clínica no es trobava estructurada explícitament segons aquestes categories, la classificació es va inferir a partir de patrons textuais presents a la metadata i posteriorment es va mapar a les categories harmonitzades definides.

2.2.2. Control del moment temporal (pre-treatment)

Per garantir un escenari predictiu clínicament realista, es va implementar un control explícit del moment temporal de les mostres, prioritzant l'ús exclusiu de dades **pre-treatment**.

En el dataset **GSE91061**, que inclou mostres recollides en diferents moments (pre-treatment i on-treatment), es van seleccionar exclusivament les mostres corresponents al moment **previ a l'inici del tractament**. Aquesta restricció evita la incorporació de perfils transcriptòmics influenciats per la pròpia immunoteràpia.

La inclusió de mostres on-treatment o post-treatment podria introduir biaixos significatius, ja que reflecteixen canvis transcriptòmics induïts pel tractament i no l'estat basal del tumor. Això podria conduir a una sobreestimació artificial del rendiment del model i a una interpretació incorrecta del seu valor predictiu.

En el cas del dataset d'entrenament **GSE160638**, es va verificar programàticament l'existència d'una possible variable temporal en la metadata. En absència d'un camp explícit de tipus *timepoint*, i d'acord amb la descripció del cohort, es va assumir el caràcter basal de les mostres utilitzades.

Aquest control es va integrar dins del pipeline per garantir la traçabilitat del preprocessament i evitar la barreja inadvertida de mostres de diferents moments temporals en futurs anàlisis.

Taula 3.1. Harmonització de la variable de resposta clínica entre els diferents cohorts utilitzats en l'estudi.

Dataset	R	NR	Exclosos
GSE160638	37	36	0
GSE91061	10	39	2
GSE78220	15	12	0

Malgrat el rigor metodològic aplicat en el desenvolupament del pipeline, aquest estudi està subjecte a diversos riscos inherents a l'anàlisi de dades transcriptòmiques en cohorts independents. En primer lloc, la presència de **batch effects** i diferències tècniques entre datasets (plataformes d'expressió, protocols de processament o normalització) pot introduir variabilitat no biològica que afecti el rendiment del model. En segon lloc, la **mida mostral limitada**, especialment en els cohorts de validació externa, pot reduir la robustesa estadística i incrementar la variabilitat de les estimacions. Addicionalment, la **heterogeneïtat biològica i clínica** entre cohorts, incloent diferències en la definició de resposta o en les característiques dels pacients, pot limitar la capacitat de generalització del model.

Per mitigar aquests riscos, s'han adoptat diverses estratègies metodològiques. S'ha implementat una **harmonització clínica estricta** basada en criteris RECIST i un control explícit del moment temporal de les mostres (pre-treatment), assegurant la coherència de la variable objectiu. A nivell tècnic, s'ha aplicat una estratègia de **normalització consistent** i s'ha restringit l'anàlisi a la intersecció

de gens comuns entre cohorts, evitant la imputació artificial de valors absents. Finalment, la utilització de **nested cross-validation** i validació externa permet obtenir estimacions robustes i realistes del rendiment del model, minimitzant el risc de sobreajust i de biaixos metodològics.

3.5. Preprocessament transcriptòmic

3.5.1. Filtrat

El preprocessament de les dades transcriptòmiques del dataset d'entrenament es va dur a terme utilitzant el paquet **edgeR** en R.

Inicialment, es va aplicar un filratge de gens amb baixa expressió mitjançant la funció *filterByExpr*, amb l'objectiu d'eliminar gens amb senyal insuficient i reduir el soroll tècnic. Aquest pas permet conservar únicament aquells gens amb una expressió consistent en un nombre mínim de mostres, adequats per a una anàlisi estadística robusta.

Després d'aquest filratge, es van mantenir els gens amb expressió rellevant per a la modelització, reduint la dimensionalitat inicial del dataset i millorant la relació senyal/soroll.

3.5.2. Normalització (TMM + logCPM)

Un cop realitzat el filratge, es va aplicar una normalització mitjançant el mètode **TMM (Trimmed Mean of M-values)**, implementat a *edgeR*, amb l'objectiu de corregir diferències de composició entre mostres i fer comparables els nivells d'expressió gènica.

Posteriorment, es va calcular una transformació a **logCPM (log-counts per million)**, que permet estabilitzar la variància i facilitar l'aplicació de mètodes estadístics i models predictius.

La matriu resultant es va utilitzar com a entrada per a l'anàlisi d'expressió diferencial i per a l'entrenament del model predictiu.

Per evitar biaixos metodològics, aquests passos de preprocessament es van aplicar exclusivament dins de cada partició d'entrenament en el marc de la validació creuada, garantint que la informació del conjunt de test no influís en el procés de normalització.

3.6. Estratègia de modelització

3.6.1. Model Random Forest

Per a la construcció del model predictiu es va utilitzar l'algoritme **Random Forest**, implementat en R mitjançant el paquet *randomForest*.

Aquest model es basa en un conjunt d'arbres de decisió entrenats sobre subconjunts aleatoris de dades i variables, i combina les seves prediccions

mitjançant un esquema d'agregació (*bagging*). Aquest enfocament permet obtenir models robustos amb baixa variància i reduir el risc de sobreajust.

En cada iteració del procés de validació, el model es va entrenar utilitzant les mostres del conjunt d'entrenament corresponent, amb la signatura gènica definida en aquella partició.

L'hiperparàmetre principal del model, **mtry** (nombre de variables considerades en cada divisió), es va optimitzar mitjançant validació creuada interna dins de cada fold d'entrenament.

3.6.2. Justificació del model

L'elecció de Random Forest es basa en diverses propietats especialment adequades per a dades transcriptòmiques:

- **Alta dimensionalitat:** permet treballar amb un nombre elevat de variables (gens) en relació amb el nombre de mostres
- **Relacions no lineals:** captura interaccions complexes entre variables sense requerir supòsits paramètrics
- **Robustesa al soroll:** és poc sensible a variables irrelevantes o correlacionades
- **Estabilitat:** redueix el risc de sobreajust mitjançant l'agregació de múltiples models

Aquestes característiques el converteixen en una opció adequada per a la predicció de resposta a immunoteràpia en contextos amb dades biològiques complexes i heterogènies.

3.7. Estratègia de validació

3.7.1. CV inicial

Com a aproximació inicial, es va utilitzar una estratègia de **validació creuada estratificada de 5 folds** per estimar el rendiment del model en el dataset d'entrenament.

En aquest esquema, el conjunt de dades es divideix en cinc subconjunts, mantenint la proporció de classes en cada partició. En cada iteració, quatre folds s'utilitzen per a l'entrenament i el fold restant per a la validació.

Aquesta aproximació permet obtenir una estimació del rendiment mitjà del model i reduir la variabilitat associada a una única partició train-test.

3.7.2. Correcció data leakage

Per garantir la validesa de l'avaluació, es va definir una estratègia en què totes les etapes del pipeline es realitzen exclusivament utilitzant dades del conjunt d'entrenament en cada iteració.

En particular, la selecció de gens diferencialment expressats, el preprocessament de les dades i l'entrenament del model es van dur a terme de manera independent dins de cada partició d'entrenament.

Aquest enfocament evita que la informació del conjunt de test influeixi indirectament en la construcció del model, assegurant així una estimació no esbiaixada del seu rendiment.

3.7.3. Validació creuada anidada (Nested CV)

Per obtenir una estimació més robusta del rendiment i optimitzar els hiperparàmetres del model, es va implementar una estratègia de **validació creuada anidada (nested cross-validation)**.

Aquest esquema consta de dos nivells:

- **Validació externa (outer loop):** utilitzada per avaluar el rendiment del model
- **Validació interna (inner loop):** utilitzada per a la selecció de variables i l'optimització d'hiperparàmetres

En cada iteració del procés:

1. El conjunt de dades es divideix en folds d'entrenament i test
2. Dins del conjunt d'entrenament:
 - Es realitza la selecció de gens diferencialment expressats
 - S'aplica el preprocessament (filtrat i normalització)
 - Es construeix la signatura gènica
 - S'optimitza l'hiperparàmetre **mtry** mitjançant validació interna
3. El model entrenat s'avalua sobre el conjunt de test corresponent

Aquest procediment garanteix que totes les decisions del model es prenen sense accedir a la informació del conjunt de test, evitant completament el **data leakage**.

A més, permet obtenir una estimació més realista de la capacitat de generalització del model, especialment en contextos amb dades d'alta dimensionalitat i mostres limitades.

3.8. Selecció de variables

3.8.1. DE genes

La selecció de variables es va basar en la identificació de gens diferencialment expressats entre responders i non-responders utilitzant el paquet **edgeR**.

Es va ajustar un model lineal generalitzat amb aproximació **quasi-likelihood**, que permet una estimació robusta de la variabilitat en dades de RNA-seq. A partir d'aquest model, es van obtenir estadístics de significació per a cada gen, que es

van utilitzar per generar un rànquing de gens segons la seva associació amb la resposta al tractament.

Per evitar biaixos metodològics, aquest procés de selecció es va realitzar exclusivament dins de cada partició d'entrenament en el marc de la validació creuada, garantint que la informació del conjunt de test no influís en la selecció de variables.

3.8.2. Comparació 50/100/250/500

A partir del rànquing de gens diferencialment expressats, es van definir diferents signatures gèniques seleccionant els gens amb major significació estadística.

Es van avaluar signatures de:

- **50 gens**
- **100 gens**
- **250 gens**
- **500 gens**

amb l'objectiu d'analitzar l'impacte de la dimensionalitat sobre el rendiment i l'estabilitat del model.

La comparació entre aquestes configuracions va permetre identificar una mida de signatura que equilibra adequadament la capacitat predictiva i la complexitat del model.

En aquest context, es va definir com a solució final una signatura de **100 gens**, ja que representa el millor compromís entre rendiment, robustesa i simplicitat, evitant la incorporació de soroll associat a signatures de major dimensionalitat.

3.9. Validació externa

3.9.1. Preparació datasets

Per avaluar la capacitat de generalització del model, es va dur a terme una validació externa utilitzant els datasets independents **GSE91061** i **GSE78220**. Prèviament a l'aplicació del model, es va realitzar una fase de preparació i harmonització de les dades amb l'objectiu de garantir la seva compatibilitat amb el conjunt d'entrenament. Aquest procés va incloure:

- Alineació de les mostres amb la seva metadata corresponent
- Harmonització de la variable de resposta clínica en categories binàries (responder / non-responder)
- Estandardització dels identificadors gènics
- Transformació de les dades d'expressió per assegurar la seva comparabilitat

En el cas de **GSE91061**, es va dur a terme la conversió d'identificadors gènics de format **Entrez ID** a **símbols gènics**. En **GSE78220**, les dades ja es trobaven en format processat (**FPKM**) amb símbols gènics disponibles.

Adicionalment, es va aplicar un control del moment temporal de les mostres, seleccionant exclusivament mostres **pre-treatment**, amb l'objectiu de mantenir un escenari predictiu realista basat en informació basal.

3.9.2. Intersecció de gens

Per garantir la coherència entre el conjunt d'entrenament i els datasets externs, es va definir un espai comú de gens compartits entre tots els cohorts.

A diferència d'un enfocament basat en la imputació de valors absents, es va restringir l'anàlisi als gens presents simultàniament en el dataset d'entrenament i en els datasets externs. Aquest procediment permet mantenir la consistència de les variables d'entrada i evitar la introducció de biaixos derivats de la imputació.

Un cop definit aquest espai comú, el model final entrenat amb el dataset **GSE160638** es va aplicar directament als datasets externs **GSE91061** i **GSE78220**, utilitzant exclusivament els gens compartits.

Aquesta estratègia garanteix una avaluació estricta de la capacitat de generalització del model en cohorts independents, tenint en compte les diferències biològiques i tècniques entre datasets.

3.10. Mètriques d'avaluació

Per tal d'avaluar el rendiment del model predictiu desenvolupat, es van utilitzar diverses mètriques estàndard en classificació binària, especialment rellevants en el context biomèdic i clínic.

3.10.1. AUC

L'àrea sota la corba ROC (Receiver Operating Characteristic) mesura la capacitat del model per discriminar entre pacients respondedors i no respondedors de manera independent del llindar de classificació.

Un valor d'AUC proper a 1 indica una excel·lent capacitat discriminativa, mentre que un valor proper a 0,5 correspon a un comportament equivalent a l'atzar. Aquesta mètrica és especialment útil en aquest context, ja que permet avaluar el rendiment global del model sense dependre d'un punt de tall específic.

3.10.2. Accuracy

L'accuracy es defineix com la proporció de mostres correctament classificades sobre el total de mostres:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Tot i ser una mètrica intuïtiva, pot resultar enganyosa en presència de desbalanceig entre classes. En aquest treball, tot i que el dataset d'entrenament presenta una distribució equilibrada, es complementa amb altres mètriques per garantir una avaluació més robusta.

3.10.3. **Balanced accuracy**

La balanced accuracy es defineix com la mitjana entre la sensibilitat i l'especificitat:

$$\text{BalancedAccuracy} = \frac{\text{Sensitivity} + \text{Specificity}}{2}$$

Aquesta mètrica és especialment rellevant en aquest estudi, ja que permet detectar possibles biaixos del model cap a una de les dues classes, especialment en els cohorts de validació externa, on la distribució de classes pot ser desigual.

3.10.4. **Sens / Spec**

- **Sensibilitat (recall o true positive rate):** proporció de pacients respondedors correctament identificats pel model.

$$\text{Sensitivity} = \frac{TP}{TP + FN}$$

- **Especificitat (true negative rate):** proporció de pacients no respondedors correctament classificats.

$$\text{Specificity} = \frac{TN}{TN + FP}$$

Aquestes dues mètriques són fonamentals en un context clínic, ja que permeten analitzar el comportament del model des de dues perspectives complementàries: la capacitat de detectar pacients que respondran al tractament i la capacitat d'evitar falsos positius.

4. Resultats

4.1. Resultats preliminars (pipeline inicial)

En una primera fase del treball es va desenvolupar un pipeline inicial utilitzant el dataset GSE160638, corresponent a pacients amb melanoma avançat tractats amb immunoteràpia anti-PD-1. Després del procés de curació de les metadades,

es va obtenir una cohort equilibrada formada per 73 mostres (37 responders i 36 non-responders).

El preprocessament de les dades es va realitzar amb el paquet *edgeR*, incloent filtratge de gens de baixa expressió i normalització TMM, obtenint una matriu final de 13.555 gens en escala logCPM.

L'anàlisi exploratòria mitjançant PCA va mostrar una separació parcial entre els grups de resposta, suggerint que la resposta a immunoteràpia està determinada per patrons transcriptòmics complexos i multivariants.



Figura 4.1. PCA de les mostres del dataset GSE160638 segons l'estat de resposta.

A partir d'una anàlisi d'expressió diferencial, es van seleccionar els 500 gens amb major senyal per entrenar un model Random Forest. El model va assolir un rendiment elevat:

- Accuracy aproximada: 86,3%
- AUC: 0,939

Tot i aquests resultats, es va identificar una limitació metodològica rellevant: la selecció de gens es realitzava abans de la validació creuada, fet que pot introduir **data leakage** i sobreestimar el rendiment.

4.2. Correcció del data leakage

Per corregir aquest problema, es va implementar una estratègia de validació creuada estratificada de 5 folds en què totes les etapes del pipeline (selecció de gens, normalització i entrenament) es realitzen exclusivament sobre les dades d'entrenament en cada iteració.

Aquest enfocament va permetre obtenir una estimació més realista del rendiment del model:

- Accuracy: 0,7808
- Balanced accuracy: 0,7800
- AUC: 0,8127




Figura 4.2. Corba ROC del model després de la correcció del data leakage (AUC = 0,813).

La reducció del rendiment respecte al pipeline inicial confirma l'existència d'una sobreestimació prèvia i valida la necessitat d'aquest refinament metodològic.

4.3. Model final (250 gens → 100 gens)

Per optimitzar el model, es va analitzar l'impacte de la mida de la signatura gènica (50, 100, 250 i 500 gens).

Taula 4.1. Comparació del rendiment segons la mida de la signatura gènica.

Nombre de gens	AUC	Accuracy	Balanced Accuracy
50	0,800	0,712	0,712
100	0,833	0,767	0,767

250	0,831	0,781	0,780
500	0,828	0,781	0,780

Els resultats mostren que una signatura de **100 gens** proporciona el millor compromís entre rendiment i complexitat.




Figura 4.3. Comparació de l'AUC segons la mida de la signatura gènica.

Finalment, es va seleccionar un model basat en 100 gens, entrenat mitjançant *nested cross-validation*, garantint l'absència de data leakage i una estimació robusta del rendiment.

4.4. Estabilitat de la signatura

Per avaluar la robustesa de la selecció gènica, es va analitzar la freqüència de selecció dels gens al llarg dels folds de la validació creuada.

Els resultats mostren:

- 688 gens seleccionats almenys una vegada
- 95 gens seleccionats en ≥ 4 folds
- 39 gens seleccionats en tots els folds




Figura 4.4. Distribució de l'estabilitat de la selecció gènica entre folds.

Aquest resultat indica l'existència d'un subconjunt de gens consistentment seleccionats, suggerint un senyal transcriptòmic robust.

4.5. Interpretació biològica

L'anàlisi d'importància de variables va identificar gens clau com CRNKL1, ZFP36, ATF3, CERS5 i ARHGAP44, associats a processos com:

- Regulació post-transcripcional
- RNA splicing
- Resposta a estrès cel·lular
- Metabolisme i proteòstasi




Figura 4.5. Importància dels gens en el model Random Forest (Top 20).

L'anàlisi d'enriquiment funcional va revelar un enriquiment dominant en processos de *RNA splicing* i regulació transcriptòmica, coherent amb els gens prioritzats.

Per visualitzar els patrons d'expressió, es va generar un heatmap dels gens més rellevants:




Figura 4.6. Heatmap dels 20 gens més importants del model.

Aquest mostra una separació parcial entre responders i non-responders, reforçant la naturalesa multigènica del fenomen.

4.6. Validació externa

Per avaluar la capacitat de generalització del model, es va dur a terme una validació externa utilitzant dos cohorts independents de melanoma tractat amb immunoteràpia anti-PD-1: GSE91061 i GSE78220.

El model utilitzat en aquesta fase correspon a la versió final del pipeline, basat en una signatura de **100 gens seleccionada mitjançant validació creuada anidada i sense presència de data leakage**.

4.6.1. Resultats del model final (100 gens)

Els resultats obtinguts en validació externa es resumeixen en la taula següent:

Taula 4.2. Resultats de validació externa del model final (100 gens).

Dataset	AUC	Accuracy	Sensitivity	Sensibility	Balanced accuracy
GSE91061	0,671	0,653	0,600	0,661	0,633
GSE78220	0,611	0,444	0,000	1,000	0,500




Figura 4.7. Corba ROC del model final en el dataset GSE91061 (AUC = 0,671).




Figura 4.8. Corba ROC del model final en el dataset GSE78220 (AUC = 0,611).

Els resultats mostren una **capacitat discriminativa moderada en GSE91061 i limitada en GSE78220**, amb una clara variabilitat en el comportament del model entre cohorts independents.

En particular, el model presenta:

- Un bon equilibri entre sensibilitat i especificitat en GSE91061
- Un comportament extrem en GSE78220, amb classificació predominant cap a no responders

Aquest patró reflecteix una **generalització heterogènia**, probablement associada a diferències biològiques, tècniques i de mida mostral entre cohorts.

4.6.2. Comparació amb la signatura de 250 gens

Amb l'objectiu de contextualitzar aquests resultats, es va comparar el rendiment del model final amb el model preliminar basat en una signatura de 250 gens.

Taula 4.3. Comparació del rendiment en validació externa entre signatures de 250 i 100 gens.

Dataset	AUC (250 gens)	AUC (100 gens)
GSE91061	0,646	0,671
GSE78220	0,711	0,611

Els resultats mostren un comportament diferent segons el cohort:

- En **GSE91061**, el model de 100 gens millora el rendiment

- En **GSE78220**, el model de 250 gens presenta una AUC superior

Tot i això, aquesta diferència s'ha d'interpretar amb cautela.

El model de 250 gens, utilitzat en fases preliminars, estava parcialment afectat per problemes metodològics com el **data leakage** i una major complexitat, fet que pot conduir a una sobreestimació del rendiment i a un major risc d'overfitting. En canvi, el model final de 100 gens:

- Elimina el data leakage
- Redueix la dimensionalitat
- Proporciona una estimació més realista del rendiment

En conjunt, els resultats mostren una capacitat predictiva moderada del model en cohorts independents, amb variabilitat en el seu rendiment segons el dataset analitzat.

4.7. Anàlisi de la calibració

Per avaluar l'impacte del llindar de classificació, es van comparar diferents estratègies:

Taula 4.4. Resultats segons el llindar de decisió

Dataset	Threshold	Sens	Spec	Balanced Acc	AUC
GSE91061	0.5	0.60	0.615	0.608	0.671
GSE91061	Youden	0.60	0.615	0.608	0.671
GSE78220	0.5	0.00	1.00	0.50	0.611

Els resultats mostren que la calibració del llindar no millora substancialment el rendiment, suggerint que la limitació principal rau en la generalització del model.

4.8. Resultats finals i comparativa

Finalment, es compara el pipeline inicial amb el model refinat:

Taula 4.5. Comparació entre models.

Aspecte	Pipeline inicial	Model final
Data leakage	Sí	No
AUC interna	0,939	0,81
Generalització	Inflada	Realista
Complexitat	Alta	Òptima
Robustesa	Baixa	Alta

En conjunt, els resultats mostren que:

- El pipeline inicial sobreestima el rendiment
- El model refinat és metodològicament més robust
- Existeix un senyal biològic real, però amb generalització limitada

Aquest treball demostra la viabilitat de construir models predictius basats en signatures transcriptòmiques, però també posa de manifest la importància de la validació rigorosa i de la gestió de la heterogeneïtat entre cohorts.

5. Discussió

5.1. Compliment dels objectius

L'objectiu principal d'aquest treball consistia en desenvolupar i validar un model predictiu robust de resposta a immunoteràpia en melanoma mitjançant un pipeline bioinformàtic reproduïble i metodològicament rigorós, amb capacitat de generalització en cohorts independents.

Aquest objectiu s'ha assolit parcialment en termes de rendiment predictiu, però de manera sòlida des d'un punt de vista metodològic.

En concret, el model desenvolupat ha mostrat una capacitat discriminativa moderada-alta en validació interna ($AUC \approx 0,81$), confirmant que és possible capturar un senyal transcriptòmic rellevant associat a la resposta a immunoteràpia. No obstant això, en validació externa, el rendiment disminueix ($AUC \approx 0,61-0,67$), evidenciant limitacions en la seva capacitat de generalització entre cohorts independents.

Aquest resultat indica que, tot i que el model compleix l'objectiu de capturar informació biològica rellevant, no assoleix plenament el requisit de transferibilitat clínica, que constituïa un element central de l'objectiu principal.

Pel que fa als objectius específics:

(1) Construcció del pipeline reproduïble → assolit completament

S'ha desenvolupat un pipeline modular, traçable i completament reproduïble, que integra totes les etapes de l'anàlisi i garanteix la separació estricta entre dades d'entrenament i test. Aquest objectiu es considera plenament complert.

(2) Harmonització i preparació de dades → assolit completament

La definició coherent de responders i non-responders segons criteris RECIST, juntament amb el control del moment temporal (pre-treatment), ha permès construir un escenari predictiu clínicament realista. Aquest objectiu s'ha assolit amb èxit.

(3) Desenvolupament del model predictiu → assolit completament

El model Random Forest implementat és capaç de capturar relacions complexes en dades transcriptòmiques i obtenir un rendiment robust en validació interna, complint així aquest objectiu.

(4) Validació rigorosa del model → assolit completament

La implementació de nested cross-validation i el control explícit del data leakage representen una de les principals fortaleeses del treball, permetent obtenir

estimacions realistes del rendiment. Aquest objectiu s'ha complert de manera sòlida.

(5) Validació externa i generalització → assolit parcialment

Tot i que el model mostra capacitat predictiva en cohorts independents, la variabilitat observada entre datasets indica una generalització limitada. Aquest objectiu s'ha assolit parcialment.

(6) Interpretació i robustesa biològica → assolit completament

L'anàlisi funcional i l'estabilitat de la signatura gènica confirmen la presència d'un senyal biològic coherent amb la literatura, complint aquest objectiu.

En conjunt, els resultats mostren que el treball compleix els objectius metodològics plantejats, però posa de manifest que el principal repte no és la construcció del model, sinó la seva capacitat de generalització en contextos clínics reals.

5.2. Compliment dels resultats

Els resultats obtinguts en aquest treball permeten avaluar de manera crítica tant la capacitat predictiva del model desenvolupat com la seva robustesa metodològica i biològica.

5.2.1. Resultats en validació interna

El model final, basat en una signatura de 100 gens i validat mitjançant *nested cross-validation*, presenta una capacitat discriminativa moderada-alta ($AUC \approx 0,81$), juntament amb valors consistents d'accuracy i *balanced accuracy*.

Aquests resultats indiquen que el model és capaç de capturar un senyal transcriptòmic real associat a la resposta a immunoteràpia. La utilització d'una estratègia lliure de *data leakage* reforça la validesa d'aquesta estimació, evitant la sobreestimació observada en fases preliminars del treball.

5.2.2. Impacte de la correcció del data leakage

Un dels resultats més rellevants del treball és la diferència observada entre el pipeline inicial i el model refinat.

Inicialment, es va obtenir un rendiment elevat ($AUC \approx 0,94$), que posteriorment es va reduir a valors més realistes ($AUC \approx 0,81$) després de corregir el *data leakage*. Aquesta reducció no representa una pèrdua de qualitat del model, sinó una millora en la seva validesa metodològica.

Aquest resultat posa de manifest la importància crítica del disseny experimental en models d'aprenentatge automàtic aplicats a dades òmiques, i constitueix una evidència clara del rigor del pipeline desenvolupat.

5.2.3. Impacte de la dimensionalitat de la signatura

L'anàlisi comparativa entre signatures de diferent mida (50, 100, 250 i 500 gens) mostra que una signatura de 100 gens proporciona el millor compromís entre rendiment i complexitat.

Aquest resultat és coherent amb el principi de parsimonia, indicant que la incorporació de més variables no implica necessàriament una millora del rendiment, sinó que pot introduir soroll i afavorir l'overfitting.

Aquesta anàlisi reforça la robustesa del model final seleccionat.

5.2.4. Resultats en validació externa

En validació externa, el model presenta una capacitat discriminativa moderada en GSE91061 (AUC $\approx$ 0,67) i limitada en GSE78220 (AUC $\approx$ 0,61), amb una variabilitat notable entre cohorts.

Aquest comportament reflecteix una generalització heterogènia, atribuïble a factors com:

- Diferències biològiques entre cohorts
- Variabilitat tècnica (plataformes, preprocessament)
- Mida mostral limitada

Tot i aquestes limitacions, els resultats confirmen l'existència d'un senyal predictiu transferible, encara que amb una magnitud moderada.

5.2.5. Anàlisi del comportament del model

L'anàlisi detallada de les mètriques mostra patrons rellevants:

- En GSE91061, el model manté un equilibri raonable entre sensibilitat i especificitat
- En GSE78220, es detecta un comportament esbiaixat cap a la classificació de no-responders

Aquest resultat suggereix que el model pot ser sensible a la distribució de classes i a les característiques específiques de cada cohort, aspecte crític en entorns clínics reals.

5.2.6. Robustesa i estabilitat de la signatura

L'anàlisi d'estabilitat de la selecció gènica mostra que existeix un subconjunt de gens consistentment seleccionats entre folds, indicant la presència d'un nucli transcriptòmic robust.

A més, l'anàlisi funcional revela un enriquiment en processos biològics coherents amb la literatura, com la regulació post-transcripcional i el RNA splicing, reforçant la plausibilitat biològica dels resultats.

5.2.7. Conclusió global dels resultats

En conjunt, els resultats obtinguts mostren que:

- El model és capaç de capturar un senyal transcriptòmic real associat a la resposta a immunoteràpia
- La seva capacitat predictiva és moderada i dependent del context del dataset
- El pipeline desenvolupat proporciona estimacions robustes i metodològicament fiables

Aquests resultats no només validen el model proposat, sinó que també evidencien les dificultats inherents a la generalització de signatures moleculars en cohorts independents, aspecte central en la bioinformàtica translacional.

5.3. Comparació amb la literatura

Els resultats obtinguts en aquest treball s'alineen de manera general amb la literatura actual en predicció de resposta a immunoteràpia en melanoma, tant pel que fa al rendiment dels models com a les dificultats associades a la seva generalització.

Diversos estudis previs han reportat models basats en dades transcriptòmiques amb valors d'AUC elevats en validació interna, habitualment en el rang aproximat de **0,75–0,85** (Hugo et al., 2016; Auslander et al., 2018). Tanmateix, aquests mateixos estudis mostren sovint una reducció del rendiment en cohorts independents, amb valors d'AUC que es situen típicament entre **0,60 i 0,75**, reflectint la dificultat de transferir signatures moleculars entre datasets heterogenis.

En aquest context, el model desenvolupat en aquest treball presenta una **AUC aproximada de 0,81 en validació interna mitjançant nested cross-validation** i valors d'AUC entre **0,61 i 0,67 en validació externa**. Aquests resultats són clarament coherents amb els reportats a la literatura, especialment pel que fa a la disminució del rendiment en cohorts independents.

A diferència d'alguns estudis previs, en què els valors elevats en validació interna poden estar influïts per biaixos metodològics, aquest treball incorpora un **control explícit del data leakage** i una estratègia de **validació creuada anidada**, assegurant que totes les etapes del pipeline (selecció de variables, preprocessament i modelització) es realitzen exclusivament dins de cada partició d'entrenament. Aquest enfocament permet obtenir una estimació més realista i no esbiaixada del rendiment del model.

A més, l'anàlisi comparativa entre signatures de diferent dimensionalitat mostra que models més complexos no impliquen necessàriament una millora del rendiment, fet també descrit en la literatura i relacionat amb el risc d'*overfitting* en dades d'alta dimensionalitat.

Des d'un punt de vista biològic, mentre que molts estudis se centren principalment en signatures associades a activació immune i infiltració

limfocitària, els resultats d'aquest treball suggereixen també un paper rellevant de processos de **regulació post-transcripcional i RNA splicing**, aportant una perspectiva complementària en la comprensió dels mecanismes de resposta a immunoteràpia.

Malgrat la coherència global amb la literatura, els resultats obtinguts posen de manifest que el principal repte en aquest camp continua sent la **generalització dels models en cohorts independents**. La variabilitat observada en validació externa, especialment entre datasets amb característiques tècniques i biològiques diferents, és consistent amb estudis previs i reflecteix limitacions inherents a l'ús de dades transcriptòmiques en contextos reals.

En conjunt, aquest treball no només confirma els patrons observats en la literatura, sinó que aporta una evidència clara de la importància del rigor metodològic en l'avaluació de models predictius. La diferència observada entre el pipeline inicial i el model final, després de corregir el *data leakage*, reforça la necessitat d'utilitzar estratègies de validació robustes per evitar estimacions inflades del rendiment.

Així, més enllà del rendiment predictiu, la principal aportació d'aquest treball rau en la implementació d'un pipeline bioinformàtic reproduïble i metodològicament rigorós, alineat amb els principis de *reproducible research*, que permet una avaluació realista i transferible en el context de la medicina de precisió.

5.4. Limitacions

Malgrat el rigor metodològic aplicat, aquest treball presenta diverses limitacions que cal considerar per interpretar adequadament els resultats i el seu potencial de transferència clínica.

En primer lloc, la **mida mostral limitada**, especialment en els cohorts de validació externa, redueix la robustesa estadística de les estimacions i incrementa la variabilitat dels resultats. Aquesta limitació és inherent a la disponibilitat de dades públiques en aquest context.

En segon lloc, existeix una elevada **heterogeneïtat entre cohorts**, tant a nivell biològic com tècnic. Diferències en plataformes d'expressió, protocols de preprocesament i característiques clíniques dels pacients poden afectar significativament el rendiment del model i dificultar la seva generalització.

En tercer lloc, tot i l'esforç d'harmonització clínica, la definició de la resposta terapèutica pot no ser completament equivalent entre datasets. En particular, la inclusió de pacients amb malaltia estable (SD) dins del grup de no-responders pot introduir variabilitat biològica en la variable objectiu.

Des d'un punt de vista metodològic, tot i la implementació de nested cross-validation i el control explícit del data leakage, el risc de sobreajust no es pot eliminar completament en dades d'alta dimensionalitat amb un nombre limitat de mostres.

A més, l'ús de dades transcriptòmiques bulk limita la capacitat de capturar la heterogeneïtat cel·lular del microambient tumoral, aspecte potencialment rellevant en la resposta a immunoteràpia.

No obstant això, és important destacar que moltes d'aquestes limitacions han estat explícitament abordades dins del disseny del pipeline. En particular:

- S'ha implementat un control estricte del data leakage
- S'ha prioritzat la validació externa en cohorts independents
- S'ha restringit l'anàlisi a gens comuns entre datasets
- S'ha definit un escenari predictiu clínicament realista (pre-treatment)

Aquest enfocament permet que les limitacions identificades no invalidin els resultats, sinó que en contextualitzin correctament l'abast i reforcin la seva interpretació.

En aquest sentit, el treball no només posa de manifest les dificultats inherents a la predicció de resposta a immunoteràpia, sinó que també evidencia la importància d'un disseny metodològic rigorós per obtenir conclusions fiables.

5.5. Implicacions clíniques

Els resultats d'aquest treball tenen implicacions rellevants en el context de la medicina de precisió.

La possibilitat de predir la resposta a immunoteràpia podria permetre:

- Seleccionar millor els pacients
- Evitar tractaments ineficaços
- Optimitzar recursos sanitaris

Aquest potencial ja es descriu en la motivació del treball i constitueix un dels principals interessos clínics del projecte .

No obstant això, el rendiment moderat en validació externa indica que el model encara no és aplicable directament en pràctica clínica.

Per avançar cap a una aplicació real, seria necessari:

- Validació en cohorts més grans
- Integració de dades multiòmiques
- Millora de la normalització inter-cohort

Per tant, aquest treball s'ha d'interpretar com una prova de concepte robusta, però encara preliminar. Des d'un punt de vista ètic, qualsevol aplicació clínica d'aquest tipus de models requereix una validació exhaustiva en cohorts independents, així com una avaluació del seu impacte en la presa de decisions mèdiques, per evitar possibles conseqüències derivades de classificacions

incorrectes. En aquest sentit, la integració responsable d'aquests models en la pràctica clínica ha de prioritzar la seguretat del pacient i la transparència en la interpretació dels resultats.

5.6. Robustesa i reproductibilitat

Un dels principals punts forts d'aquest treball és l'èmfasi en la robustesa metodològica i la reproductibilitat del pipeline desenvolupat, aspectes fonamentals en el context de la bioinformàtica translacional.

En primer lloc, el disseny del pipeline garanteix una **separació estricta entre les dades d'entrenament i test en totes les etapes de l'anàlisi**, evitant qualsevol forma de *data leakage*. Aquest control s'implementa de manera sistemàtica, assegurant que tant la selecció de variables com el preprocessament i l'entrenament del model es realitzen exclusivament dins de cada partició d'entrenament.

A més, la utilització de **validació creuada anidada (nested cross-validation)** permet obtenir estimacions robustes i no esbiaixades del rendiment del model, integrant en un mateix marc la selecció de variables, l'optimització d'hiperparàmetres i l'avaluació final. Aquest enfocament representa una millora significativa respecte a aproximacions més simples i constitueix una de les aportacions metodològiques principals del treball.

Des del punt de vista de la reproductibilitat, el pipeline ha estat implementat seguint principis de **modularitat, traçabilitat i separació de fases**, amb una estructura clara entre dades, processament i resultats. Aquesta organització permet reproduir completament l'anàlisi, així com adaptar-lo fàcilment a nous datasets o escenaris clínics.

Addicionalment, l'anàlisi d'estabilitat de la signatura gènica mostra l'existència d'un **nucli de gens seleccionats de manera consistent entre folds**, suggerint que el model captura un senyal transcriptòmic robust i no depèn excessivament d'una partició concreta de les dades.

No obstant això, els resultats de validació externa evidencien que la **robustesa interna del model no es tradueix completament en robustesa externa**, amb una variabilitat notable del rendiment entre cohorts. Aquest fet posa de manifest que el principal repte en aquest tipus de models no és la seva reproducció tècnica, sinó la seva capacitat de generalització en entorns biològicament i tècnicament heterogenis.

En aquest context, el pipeline desenvolupat constitueix una base sòlida i metodològicament fiable, alineada amb els principis de *reproducible research* i *open science*, i representa un pas rellevant cap a la seva futura aplicació en medicina de precisió.

En aquest sentit, els resultats d'aquest treball reforcen la idea que, en el context de la bioinformàtica translacional, el principal repte no és assolir un alt rendiment en validació interna, sinó garantir la seva transferibilitat en cohorts independents,

aspecte que continua sent una limitació estructural en el desenvolupament de signatures moleculars.

6. Conclusions i treball futur

6.1. Conclusions

Aquest treball ha tingut com a objectiu desenvolupar i validar un model predictiu de resposta a immunoteràpia en melanoma basat en dades transcriptòmiques, mitjançant un pipeline bioinformàtic reproduïble i metodològicament rigorós.

Els resultats obtinguts permeten extreure diverses conclusions rellevants.

En primer lloc, s'ha demostrat la viabilitat de construir un pipeline complet que integra preprocessament, selecció de variables i modelització, incorporant bones pràctiques com el control explícit del *data leakage* i la validació creuada anidada. Aquest enfocament constitueix una aportació metodològica clau, ja que permet obtenir estimacions realistes i fiables del rendiment del model.

En segon lloc, el model desenvolupat, basat en una signatura de 100 gens, és capaç de capturar un senyal transcriptòmic associat a la resposta a immunoteràpia, amb una capacitat discriminativa moderada-alta en validació interna ($AUC \approx 0,81$) i moderada en validació externa (AUC entre 0,61 i 0,67).

En tercer lloc, els resultats evidencien que la resposta a immunoteràpia és un fenomen complex i multigènic, en què intervenen múltiples processos biològics, incloent la regulació post-transcripcional, el RNA splicing i la resposta a estrès cel·lular.

No obstant això, el treball també posa de manifest que el principal repte en aquest camp no és la construcció del model, sinó la seva capacitat de generalització en cohorts independents. La variabilitat observada en validació externa reflecteix la heterogeneïtat biològica i tècnica inherent a les dades transcriptòmiques.

En aquest sentit, aquest treball s'ha d'interpretar com una prova de concepte robusta, que demostra tant el potencial com les limitacions de les signatures moleculars en la predicció de la resposta a immunoteràpia.

6.1.1. Conclusió final

En conclusió, aquest TFM no només aporta un model predictiu, sinó també un marc metodològic sòlid per a l'anàlisi de dades òmiques en contextos clínics, posant en valor la importància de la reproductibilitat, el control del biaix i la validació rigorosa com a requisits essencials per a la transferència cap a la medicina de precisió.

6.2. Aportacions del treball

Aquest treball aporta contribucions rellevants tant des d'un punt de vista metodològic com aplicat, amb un èmfasi especial en la robustesa, la reproductibilitat i la validesa dels resultats en contextos reals.

6.2.1. Aportacions metodològiques

Des d'una perspectiva metodològica, destaca el desenvolupament d'un pipeline bioinformàtic completament reproduïble que integra bones pràctiques en l'anàlisi de dades òmiques. En particular, el treball incorpora:

- Control explícit del data leakage en totes les etapes del pipeline
- Implementació de validació creuada anidada (nested cross-validation)
- Separació estricta entre dades d'entrenament i test
- Validació externa en cohorts independents

Aquest conjunt d'estratègies permet obtenir estimacions realistes i no esbiaixades del rendiment del model, evitant la sobreestimació observada en aproximacions més simples.

Un dels aspectes més rellevants del treball és la identificació i correcció del problema de data leakage en el pipeline inicial. La reducció del rendiment observada després d'aquesta correcció no representa una pèrdua de qualitat, sinó una millora en la validesa metodològica, i posa de manifest la importància del disseny experimental en models predictius aplicats a dades transcriptòmiques.

A més, el pipeline ha estat dissenyat seguint principis de modularitat i traçabilitat, facilitant la seva reutilització i extensió a nous datasets o escenaris clínics.

6.2.2. Innovació del treball

Tot i que el treball no proposa un nou algoritme de classificació, la seva innovació rau en la definició d'un enfocament metodològic orientat a la generalització real dels models en bioinformàtica translacional.

En primer lloc, el pipeline ha estat dissenyat explícitament per simular un escenari clínic real, en què la predicció es basa exclusivament en dades pre-treatment i s'avalua en cohorts completament independents. Aquest enfocament contrasta amb molts estudis previs, centrats principalment en validació interna, i aporta una perspectiva més alineada amb la medicina de precisió.

En segon lloc, el treball introdueix un control sistemàtic i rigorós del data leakage, assegurant que la selecció de variables, el preprocessament i l'entrenament del model es realitzen exclusivament dins de cada partició d'entrenament. Aquesta estratègia garanteix que les estimacions de rendiment siguin realistes i transferibles, evitant resultats inflats.

En tercer lloc, es prioritza la validació externa en múltiples cohorts independents (GSE91061 i GSE78220), incorporant decisions metodològiques clau com la restricció a gens comuns entre datasets i l'evitació d'imputacions artificials.

Aquest disseny permet avaluar de manera estricta la capacitat de generalització del model en escenaris heterogenis.

Adicionalment, el treball aporta una anàlisi sistemàtica de la dimensionalitat de la signatura gènica, comparant diferents configuracions (50, 100, 250 i 500 gens) i identificant una solució òptima basada en criteris de rendiment, robustesa i simplicitat. Aquesta aproximació reforça l'aplicabilitat pràctica del model i evita l'ús de signatures sobredimensionades.

Finalment, des d'un punt de vista biològic, el treball identifica processos menys explorats en aquest context, com la regulació post-transcripcional i el RNA splicing, aportant una visió complementària a les signatures clàssiques basades en activació immune.

En conjunt, la innovació d'aquest treball no resideix únicament en el model desenvolupat, sinó en la capacitat de construir un pipeline metodològicament rigorós que permet una avaluació realista, reproducible i transferible en el context de la predicció de resposta a immunoteràpia.

6.2.3. Aportació global

En conjunt, aquest treball constitueix una prova de concepte sòlida que demostra que és possible desenvolupar models predictius basats en dades transcriptòmiques amb un alt grau de rigor metodològic.

A diferència d'altres aproximacions centrades principalment en el rendiment predictiu, aquest treball posa un èmfasi explícit en la validesa dels resultats, la reproductibilitat i la capacitat de generalització, aspectes clau per a la seva futura aplicació en medicina de precisió.

Així, més enllà del model desenvolupat, la principal aportació del treball rau en l'establiment d'un marc metodològic robust per a l'anàlisi de dades òmiques en contextos clínics, alineat amb els principis de *reproducible research* i bioinformàtica translacional.

En aquest sentit, la innovació principal del treball no rau en el desenvolupament d'un nou model, sinó en la definició d'un pipeline orientat a la validació real i la generalització, aspecte sovint infrarepresentat en estudis previs.

6.3. Limitacions i treball futur

Malgrat els resultats obtinguts, aquest treball presenta diverses limitacions que obren línies clares de treball futur.

En primer lloc, la mida mostral és limitada, especialment en la validació externa, fet que pot afectar la robustesa de les estimacions i la capacitat de generalització del model.

En segon lloc, existeix una elevada heterogeneïtat entre cohorts, tant a nivell biològic com tècnic, incloent diferències en plataformes, preprocessament i definició clínica de la resposta. Aquest factor es configura com el principal repte per a la transferibilitat del model.

En tercer lloc, tot i el procés d'harmonització clínica, la definició de la resposta terapèutica pot no ser completament equivalent entre datasets, introduint una font potencial de biaix.

A més, l'ús de dades transcriptòmiques bulk limita la capacitat d'interpretar la contribució específica dels diferents tipus cel·lulars del microambient tumoral.

En aquest context, futures línies de treball haurien d'incloure:

- Validació en cohorts més grans i homogenis
- Desenvolupament d'estratègies de normalització inter-cohort més robustes
- Integració de dades multiòmiques (genòmica, epigenòmica, proteòmica)
- Incorporació de dades de *single-cell RNA-seq* per capturar la heterogeneïtat cel·lular
- Exploració de models més avançats o híbrids (ensemble, deep learning)
- Refinament de la selecció de variables incorporant criteris d'estabilitat i coneixement biològic

Finalment, per a una aplicació clínica real, serà imprescindible validar aquestes signatures en cohorts prospectius i en entorns clínics controlats.

6.4. Conclusió final

Aquest treball demostra que el desenvolupament de models predictius basats en dades transcriptòmiques requereix no només capacitat tècnica, sinó un rigor metodològic estricte orientat a la generalització.

Els resultats evidencien que el principal repte no és assolir un alt rendiment en validació interna, sinó garantir la seva transferibilitat en cohorts independents.

En aquest context, el pipeline desenvolupat constitueix una aportació sòlida, reproducible i alineada amb els principis de la bioinformàtica translacional i la medicina de precisió.

7. Glossari

AUC (Area Under the Curve)

Mesura de la capacitat discriminativa d'un model de classificació. Un valor proper a 1 indica un rendiment excel·lent, mentre que 0,5 correspon a classificació aleatòria.

Accuracy

Proporció de mostres correctament classificades respecte al total.

Balanced accuracy

Mitjana entre sensibilitat i especificitat. Especialment útil en datasets amb desbalanceig de classes.

Biomarcador molecular

Característica biològica mesurable (en aquest cas, expressió gènica) associada a un procés clínic, com la resposta a tractament.

Cross-validation (CV)

Estratègia de validació basada en particions del dataset per estimar el rendiment del model.

Data**leakage**

Error metodològic en què informació del conjunt de test s'utilitza indirectament durant l'entrenament, provocant una sobreestimació del rendiment.

Dataset (cohort)

Conjunt de dades d'expressió gènica i informació clínica associada.

Differential Expression (DE)

Anàlisi estadística per identificar gens amb diferències d'expressió significatives entre grups.

FPKM (Fragments Per Kilobase Million)

Mesura normalitzada d'expressió gènica utilitzada en dades RNA-seq processades.

Gene signature (signatura gènica)

Conjunt de gens seleccionats que permeten discriminar entre condicions biològiques o clíniques.

Immunoteràpia (anti-PD-1)

Tractament basat en la modulació del sistema immunitari per atacar cèl·lules tumorals.

Nested cross-validation

Estratègia de validació amb dos nivells (intern i extern) que permet optimitzar hiperparàmetres evitant data leakage.

Pipeline bioinformàtic reproduïble

Flux de treball estructurat i documentat que permet reproduir tots els passos de l'anàlisi.

Random Forest

Algorisme d'aprenentatge automàtic basat en múltiples arbres de decisió combinats (ensemble learning).

RECIST (Response Evaluation Criteria in Solid Tumors)

Criteris estàndard per avaluar la resposta tumoral (CR, PR, SD, PD).

Responder / Non-responder

Classificació binària dels pacients segons la seva resposta al tractament.

RNA-seq

Tecnologia de seqüenciació que permet quantificar l'expressió gènica a nivell transcriptòmic.

TMM (Trimmed Mean of M-values)

Mètode de normalització per corregir diferències de composició en dades RNA-seq.

logCPM (log-counts per million)

Transformació logarítmica de les dades d'expressió per estabilitzar la variància.

Overfitting (sobreajust)

Situació en què el model s'adapta excessivament a les dades d'entrenament i perd capacitat de generalització.

8. Bibliografia

Articles científics

- Hugo, W., et al. (2016). *Genomic and Transcriptomic Features of Response to Anti-PD-1 Therapy in Metastatic Melanoma*. **Cell**, 165(1), 35–44.
- Riaz, N., et al. (2017). *Tumor and Microenvironment Evolution during Immunotherapy with Nivolumab*. **Cell**, 171(4), 934–949.
- Gide, T. N., et al. (2019). *Distinct Immune Cell Populations Define Response to Anti-PD-1 Monotherapy and Anti-PD-1/Anti-CTLA-4 Combined Therapy*. **Cancer Cell**, 35(2), 238–255.
- Auslander, N., et al. (2018). *Robust prediction of response to immune checkpoint blockade therapy in metastatic melanoma*. **Nature Medicine**, 24, 1545–1549.
- Liu, D., et al. (2019). Integrative molecular and clinical modeling of clinical outcomes to PD-1 blockade in patients with metastatic melanoma. *Nature Medicine*, 25(12), 1916–1927.
- Litchfield, K., et al. (2021). Meta-analysis of tumor- and T cell-intrinsic mechanisms of sensitization to checkpoint inhibition. *Cell*, 184(3), 596–614.
- Chowell, D., et al. (2022). Improved prediction of immune checkpoint blockade efficacy across multiple cancer types. *Nature Biotechnology*, 40, 499–506.

- Auslander, N., et al. (2021). Machine learning–based prediction of response to immunotherapy using gene expression data. *Nature Communications*, 12, 1–13.
- Hu, X., et al. (2023). Deep learning for predicting immunotherapy response from transcriptomic data. *Briefings in Bioinformatics*, 24(1).

Metodologia bioinformàtica i estadística

- Robinson, M. D., McCarthy, D. J., & Smyth, G. K. (2010). *edgeR: a Bioconductor package for differential expression analysis of digital gene expression data*. **Bioinformatics**, 26(1), 139–140.
- Breiman, L. (2001). *Random Forests*. **Machine Learning**, 45(1), 5–32.
- Kuhn, M. (2008). *Building Predictive Models in R Using the caret Package*. **Journal of Statistical Software**, 28(5).
- Fawcett, T. (2006). *An introduction to ROC analysis*. **Pattern Recognition Letters**, 27(8), 861–874.
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning*. Springer.
- Sandve, G. K., et al. (2013). Ten simple rules for reproducible computational research. *PLOS Computational Biology*, 9(10).

Bases de dades utilitzades

- Edgar, R., Domrachev, M., & Lash, A. E. (2002). Gene Expression Omnibus: NCBI gene expression and hybridization array data repository. *Nucleic Acids Research*, 30(1), 207–210.
- Gene Expression Omnibus (GEO), NCBI
<https://www.ncbi.nlm.nih.gov/geo/>
 - GSE160638
 - GSE91061
 - GSE78220

Paquets i eines de software

- R Core Team (2024). *R: A Language and Environment for Statistical Computing*.
<https://www.r-project.org/>
- Bioconductor Project
<https://www.bioconductor.org/>
- Paquets utilitzats:
 - edgeR
 - randomForest
 - caret
 - pROC
 - clusterProfiler
 - org.Hs.eg.db
 - ggplot2

Referències conceptuals

- Topalian, S. L., et al. (2012). *Safety, activity, and immune correlates of anti-PD-1 antibody in cancer*. **New England Journal of Medicine**, 366(26), 2443–2454.
- Hanahan, D. (2022). *Hallmarks of Cancer: New Dimensions*. **Cancer Discovery**, 12(1), 31–46.
- Hegde, P. S., & Chen, D. S. (2020). Top 10 challenges in cancer immunotherapy. *Immunity*, 52(1), 17–35.

9. Annexos

9.1. Arquitectura del pipeline bioinformàtic

El pipeline desenvolupat en aquest treball s'ha dissenyat seguint principis de **modularitat, traçabilitat i reproductibilitat**, amb l'objectiu de garantir la seva reutilització en futurs estudis i en entorns clínics reals.

L'arquitectura del projecte es basa en una separació clara entre dades, processament i resultats, estructurada de la següent manera:

```
TFM_immunotherapy
├── data_processed
├── data_raw
├── figures
├── README.md
├── results
├── scripts
│   ├── 01_load_data.R
│   ├── 02_preprocessing.R
│   ├── 03_exploratory_analysis.R
│   ├── 04_differential_expression.R
│   ├── 05_model_training_nestedCV.R
│   ├── 06_external_validation.R
│   └── 07_gene_stability_analysis.R
```

Aquesta organització permet:

- Separació estricta entre dades originals i dades processades
- Traçabilitat completa de cada pas de l'anàlisi
- Execució modular del pipeline
- Facilitat d'extensió a nous datasets

Aquest disseny és coherent amb les bones pràctiques en bioinformàtica i evita dependències implícites entre fases.

9.2. Entorn computacional i dependències

L'anàlisi s'ha desenvolupat íntegrament en **R**, utilitzant eines de l'ecosistema CRAN i Bioconductor.

Configuració de l'entorn:

- Sistema operatiu: macOS
- R: versió 4.5.1
- Bioconductor: versió compatible amb R utilitzat

Paquets principals:

Categoria	Paquet	Funció
Preprocessament	edgeR	Filtrat i normalització RNA-seq
Modelització	randomForest	Classificador
Validació	caret	Cross-validation i tuning
Avaluació	pROC	Corbes ROC i AUC
Visualització	ggplot2	Figures
Anàlisi funcional	clusterProfiler	Enriquiment
Anotació	Org.Hs.eg.db	Mapping gènic

Aquest conjunt de dependències permet cobrir tot el flux d'anàlisi, des de dades crues fins a interpretació biològica.

9.3. Descripció formal del pipeline

El pipeline implementat segueix una seqüència estructurada de passos:

1. Obtenció i curació de dades

- Descàrrega de datasets des de GEO
- Extracció i alineació de metadades
- Curació de la variable resposta

2. Harmonització clínica

- Definició unificada de responders (CR/PR) i non-responders (SD/PD)
- Exclusió de casos amb informació ambigua
- Control explícit del moment temporal (pre-treatment)

3. Preprocessament transcriptòmic

- Filtrat de gens amb baixa expressió (*filterByExpr*)
- Normalització TMM
- Transformació logCPM

4. Selecció de variables

- Anàlisi d'expressió diferencial (edgeR GLM QL)
- Rànquing de gens segons significació
- Selecció dinàmica dins de cada fold

5. Modelització

- Entrenament amb Random Forest
- Optimització de *mtry* via validació interna

6. Validació

- Nested cross-validation
- Control estricte de data leakage

7. Validació externa

- Harmonització de datasets externs
- Intersecció de gens comuns
- Aplicació directa del model

8. Avaluació

- AUC
- Accuracy
- Balanced accuracy
- Sensibilitat / Especificitat

9. Interpretació

- Importància de variables
- Anàlisi funcional (GO, KEGG, Reactome)

Aquest disseny garanteix una separació estricta entre entrenament i test en totes les etapes.

9.4. Control del data leakage

Un dels aspectes clau del pipeline és el control explícit del **data leakage**, implementat mitjançant:

- Selecció de gens dins de cada fold
- Normalització independent per partició
- Separació estricta train/test
- Nested cross-validation

Aquest enfocament assegura que:

- Cap informació del conjunt de test influeix en la construcció del model

Aquest punt és crític i constitueix una de les principals aportacions metodològiques del treball.

9.5. Implementació del model

El model predictiu es basa en Random Forest, amb la següent configuració general:

```

1 set.seed(123)
2
3 model <- randomForest(
4   x = train_data,
5   y = as.factor(train_labels),
6   ntree = 500,
7   mtry = tuned_mtry,
8   importance = TRUE
9 )

```

Característiques del model:

- Capacitat per manejar alta dimensionalitat
- Robustesa davant soroll
- Captura de relacions no lineals
- Estabilitat mitjançant agregació

Aquest model és especialment adequat per dades transcriptòmiques.

9.6. Estratègia d'intersecció de gens

Per garantir la coherència entre cohorts:

- Es defineix un espai comú de gens
- S'eliminen gens absents en datasets externs
- No s'utilitza imputació artificial

Aquest enfocament:

- Evita biaixos
- Manté consistència biològica
- Millora la interpretabilitat

9.7. Anàlisi d'estabilitat de la signatura

La robustesa de la selecció gènica s'ha avaluat mitjançant:

- Freqüència de selecció per fold
- Identificació de gens consistents
- Comparació de signatures alternatives

Aquest anàlisi permet:

- Detectar un nucli transcriptòmic robust
- Reduir dependència del dataset
- Millorar interpretabilitat biològica

9.8. Materials suplementaris

Els següents materials estan disponibles com a suport:

- Resultats complets d'expressió diferencial
- Llistat complet de gens seleccionats
- Resultats detallats de validació
- Figures addicionals (PCA, ROC, heatmaps)

Aquest conjunt permet una revisió exhaustiva dels resultats.

9.9. Reproductibilitat i reutilització

El pipeline desenvolupat garanteix:

- Reproducció completa dels resultats
- Modularitat del codi
- Facilitat d'adaptació a nous datasets
- Traçabilitat de decisions

Aquest enfocament s'alinea amb els principis de:

- **Reproducible research**
- **Open science**
- **Bioinformàtica translacional**

9.10. Limitacions tècniques del pipeline

Tot i el rigor metodològic, el pipeline presenta algunes limitacions:

- Dependència de la qualitat de les metadades
- Heterogeneïtat entre cohorts
- Limitacions de dades bulk RNA-seq
- Absència d'integració multiòmica

Aquestes limitacions constitueixen oportunitats de millora futura.